

Imię i nazwisko	Numer Indeksu	Grupa
Daniel Madziński	150180	L3
Jakub Sikorski	162256	L3

Multiple Sequence Alignment dla DNA z algorytmem genetycznym

1. Opis problemu Multiple Sequence Alignment

Multiple Sequence Alignment polega na jednoczesnym dopasowaniu wielu sekwencji biologicznych. W tym projekcie rozpatrywane są sekwencje DNA z alfabetu A, C, G, T. Dopasowanie może zawierać znaki przerwy "-", które oznaczają luki. Celem jest takie ustawienie sekwencji w kolumnach, aby podobne znaki były ustawione względem siebie, a całe dopasowanie miało jak najwyższą wartość funkcji celu.

MSA jest traktowane jako problem optymalizacyjny. Rozwiązaniem jest macierz znaków, w której każdy wiersz odpowiada jednej sekwencji po dodaniu luk. Wszystkie wiersze mają taką samą długość. Po usunięciu luk z wiersza musi powstać oryginalna sekwencja wejściowa.

2. Funkcja celu

Zastosowano funkcję Sum-of-Pairs. Dla każdej pary sekwencji liczony jest wynik dopasowania, a końcowy wynik alignmentu jest sumą wyników wszystkich par.

Punktacja:

Relacja	Punkty
match	+1
mismatch	-1
gapopen	-2
gapextend	-1
gap-gap	0

Kary za luki są liczone osobno dla każdej pary sekwencji. Pierwsza relacja znak-gap oznacza gapopen, a kolejne przedłużenie tej samej luki oznacza gapextend. Jeżeli poprzednia kolumna dla pary zawierała gap-gap, to stan luki nie jest kontynuowany. Dlatego znak -gap po gap-gap jest liczony jako nowe otwarcie luki.

3. Reprezentacja dopasowania

Alignment jest reprezentowany jako macierz list[list[str]]. Wiersze mają wspólną długość, a znak “-” oznacza gap. Program pilnuje trzech warunków poprawności:

- każdy wiersz po usunięciu gapów daje oryginalną sekwencję,
- wszystkie wiersze mają taką samą długość,
- nie występują kolumny złożone wyłącznie z gapów.

Taka reprezentacja odpowiada również binarnej interpretacji z dokumentu: znak sekwencji oznacza 1, a gap oznacza 0.

4. Algorytm Genetyczny

Osobnikiem w algorytmie jest pełny alignment. Populacja początkowa składa się z losowo wygenerowanych dopuszczalnych alignmentów. W każdej generacji program oblicza SP-score, wybiera rodziców, tworzy potomków przez krzyżowanie i mutacje, naprawia alignmenty oraz przenosi najlepszego osobnika do kolejnej generacji.

Zastosowane elementy GA:

- selekcja turniejowa,
- krzyżowanie jednopunktowe po zgodnych pozycjach,
- uzupełnianie potomka losową poprawną końcówką, jeżeli rodzice nie mają zgodnego miejsca cięcia,
- shift mutation przesuująca blok gapów o jedną kolumnę w lewo albo w prawo,
- elityzm z jednym najlepszym osobnikiem,
- stop po ustalonej liczbie generacji.

5. Parametry algorytmu

Domyślne parametry:

Parametr	Wartość
Liczebność populacji	50
Liczba generacji	150
Rozmiar turnieju	3
Prawdopodobieństwo krzyżowania	0.85
Prawdopodobieństwo mutacji	0.25
Seed	42

6. Eksperyment

Eksperyment wykonano dla trzech małych zestawów DNA z katalogu test_data. Miara początkowa to najlepszy wynik w populacji startowej, a miara końcowa to najlepszy wynik po zakończeniu GA. Użyto domyślnych parametrów programu: populacja 50, 150 generacji, turniej 3, prawdopodobieństwo krzyżowania 0.85, prawdopodobieństwo mutacji 0.25 oraz seed 42.

Zestaw	Sekwencje	Cel eksperymentu
Przykład z PDF	AGTCGTAG, ATCGTCG, GTAG, GTAGAG	sprawdzenie działania na danych z treści PDF
Zestaw 1 (small_1)	ACGTACGT, ACGTCGT, ACGACGT, CGTACG	krótkie sekwencje o widocznym podobieństwie
Zestaw 2 (small_2)	GATTACA, GATACA, GACTACA, TACTA	sekwencje z różnymi lokalnymi brakami i niezgodnościami

Uzyskane wyniki:

Zestaw	Wynik początkowy	Wynik końcowy	Poprawa procentowa	Czas
Przykład z PDF	-50	-6	88.00%	2.6095 s
Zestaw 1 (small_1)	-58	12	120.69%	2.1374 s
Zestaw 2 (small_2)	-46	-15	67.39%	2.6702 s

Przykład z PDF został użyty do weryfikacji funkcji celu. Ręcznie podany alignment z dokumentu ma wynik SP = -9. Natomiast w eksperymencie GA startuje od samych sekwencji bez gapów i sam szuka alignmentu. Dla tych samych sekwencji wejściowych algorytm znalazł lepszy alignment o wyniku SP = -6.

7. Testy parametrów

Dla rozszerzonej analizy wykonano testy trzech najważniejszych parametrów algorytmu genetycznego:

- liczebności populacji,
- prawdopodobieństwa mutacji,
- prawdopodobieństwa krzyżowania.

Każdy wariant parametru był uruchamiany na trzech zestawach danych. Dla każdego zestawu wykonano 3 powtórzenia z różnymi ziarnami generatora losowego, czyli każdy wpis w tabeli powstał z 9 uruchomień programu. Pozostałe parametry były stałe: 80 generacji, turniej 3, populacja 50, mutacja 0.25 i krzyżowanie 0.85, chyba że dany parametr był właśnie testowany.

Liczebność populacji

Populacja	Średni wynik początkowy	Średni wynik końcowy	Najlepszy wynik	Odchylenie	Średnia poprawa	Średni czas
20	-62.78	-17.67	12	17.98	72.22%	0.6826 s
40	-53.22	-16.33	-5	7.64	69.37%	1.4196 s
60	-50.22	-8.33	12	10.60	84.08%	2.1756 s

Większa populacja poprawiła średni wynik końcowy, ale zwiększyła czas działania. Populacja 60 dała najlepszy średni wynik, ponieważ zapewnia większą różnorodność alignmentów startowych i więcej kandydatów do selekcji.

Prawdopodobieństwo mutacji

Mutacja	Średni wynik początkowy	Średni wynik końcowy	Najlepszy wynik	Odchylenie	Średnia poprawa	Średni czas
0.10	-52.67	-6.56	12	8.90	87.71%	1.7212 s
0.25	-52.67	-9.00	12	16.47	84.48%	1.6324 s
0.40	-52.67	-7.67	12	12.75	86.30%	1.3088 s

Najlepszy średni wynik uzyskano dla mutacji 0.10. Mutacja 0.25 i 0.40 również poprawiały rozwiązania, ale dawały większy rozrzut wyników. W tym projekcie mutacja przesuwania bloków, więc zbyt częste jej stosowanie może naruszać dobre lokalne ustawienia znalezione przez krzyżowanie i selekcję.

Prawdopodobieństwo krzyżowania

Krzyżowanie	Średni wynik początkowy	Średni wynik końcowy	Najlepszy wynik	Odchylenie	Średnia poprawa	Średni czas
0.60	-52.67	-9.56	12	10.88	82.16 %	1.3004 s
0.85	-52.67	-9.00	12	16.47	84.48%	1.2221 s
1.00	-52.67	-11.44	12	12.55	79.14%	1.2238 s

Najlepsza średnia poprawa pojawiła się dla krzyżowania 0.85. Wariant 1.00 nie był najlepszy, co sugeruje, że pozostawienie części potomków bez krzyżowania pomaga utrzymać dobre osobniki i ogranicza zbyt agresywne mieszanie alignmentów.

8. Analiza wyników

We wszystkich testach widoczna była poprawa względem populacji początkowej. Najsilniejszy wpływ na średnią jakość miała liczebność populacji: większa populacja dała lepsze wyniki, ale kosztem czasu. Dla mutacji najlepsze wyniki uzyskano przy wartości 0.10, co oznacza, że umiarkowana eksploracja lokalna wystarcza dla małych instancji DNA. Dla krzyżowania najlepszy kompromis uzyskano przy wartości 0.85.

Wyniki mają pewien rozrzut, ponieważ GA jest algorytmem losowym. Dlatego pojedyncze uruchomienie nie wystarcza do oceny parametrów. Średnia z wielu uruchomień pokazuje bardziej wiarygodny trend niż najlepszy pojedynczy wynik.

Na podstawie eksperymentów jako sensowny zestaw parametrów dla tego projektu można wskazać: populacja 60, mutacja 0.10, krzyżowanie 0.85, turniej 3 oraz limit generacji dobrany do dostępnego czasu.

9. Wnioski

Algorytm genetyczny pozwala uzyskać dopuszczalne dopasowania i stopniowo poprawiać ich wynik. Najważniejsze dla poprawności są reprezentacja, naprawa osobników po operatorach oraz dokładne liczenie kar gapopen i gapextend. Testy parametrów pokazują, że jakość wyniku zależy od równowagi między różnorodnością populacji, krzyżowaniem oraz mutacją. Rozszerzone eksperymenty potwierdzają, że program nadaje się nie tylko do pojedynczego uruchomienia, ale też do porównywania konfiguracji algorytmu.